

ANÁLISIS EXPLORATORIO Y PREPARACIÓN DE DATOS

DIAGNÓSTICO Y LIMPIEZA
DE UN DATASET DE
RENDIMIENTO ACADÉMICO

Javiera Cuevas, Arline Mitchell, Nicolás Morales y
Antonia Peña

Inteligencia Artificial | Jazna Meza Hidalgo



Contexto y objetivo

Una institución educativa quiere analizar el rendimiento de sus estudiantes para entender qué factores influyen en la nota final (FinalGrade).

El objetivo principal es generar un proceso completo de EDA y preparación de datos para dejar el dataset (rendimiento_academico_evaluacion.csv) limpio y listo para un futuro modelo predictivo.



Principales Problemas de Calidad



Valores faltantes

- Problema: Casi todas las variables tenían datos faltantes.
- Cantidad: Un total de 1,335 valores nulos.
- Las más afectadas: Attendance (4.39%), AssignmentsCompleted (4.23%) y StudyHours (3.54%).
- Decisión: Como los porcentajes son bajos (<5%), se imputarán (rellenarán) en lugar de eliminar las filas.

Registros Duplicados

- Problema: Se encontraron filas completamente idénticas.
- Cantidad: 100 duplicados (1.96%).
- Decisión: Eliminar los duplicados para evitar sesgar el análisis.

Principales Problemas de Calidad




Inconsistencias Lógicas

- Problema: Valores imposibles para la realidad de las variables., como Edad de 75 años, Asistencia negativa o superior al 100%, Notas fuera del rango de 1 a 10 (ej. -0.28 o 0.26).
- Cantidad: 24 registros con estos problemas.
- Decisión: Convertir estos valores a NaN para que el Pipeline los impute.

Inconsistencias Estructurales

- Problema: Errores tipográficos y de formato en las columnas de texto.
- Decisión: Normalizar el texto (minúsculas, eliminar tildes y espacios).



Exploratory Data Analysis (EDA)

- Distribución de Variables: FinalGrade tiene una distribución casi normal, ideal para modelos predictivos.
- Matriz de correlación: Las relaciones lineales más fuertes y significativas con respecto a la calificación final son
 - a. AssignmentsCompleted (Correlación: 0.68)
 - b. PreviousGPA (Correlación: **0.65**)
 - c. Attendance (Correlación: **0.59**)
 - d. StudyHours también tiene una correlación positiva moderada (**0.49**)
- Conclusión Clave: Los hábitos de estudio y el desempeño previo son los factores más determinantes para la nota final.


Resultados del EDA

Beca y Rendimiento: Los estudiantes con beca tienen un promedio 0.30 puntos más alto que los que no tienen.

Programa con mejor rendimiento: Ingeniería Informática (promedio 4.23) versus Contador Auditor (promedio 4.05), una diferencia de 0.19 puntos.

Relación StudyHours vs FinalGrade: Correlación positiva moderada de 0.49. Más horas de estudio se asocian a mejores notas.

Relación Attendance vs FinalGrade: Correlación positiva de 0.59. Los estudiantes con mayor asistencia tienden a tener mejor rendimiento.




Decisiones de tratamiento

==




Valores Atípicos (Outliers)

No se eliminan, se usa StandardScaler en el Pipeline para reducir su influencia en el modelo.



Valores Faltantes


Númericos: Imputar con la **Mediana** (robusta a valores atípicos).
Categoricos: Imputar con la **Moda** (el valor más frecuente).



Inconsistencias y Duplicados

Inconsistencias: Se convirtieron valores ilógicos a NaN y se normalizó el texto de las categóricas.
Duplicados: Eliminados para evitar duplicidad de información.

Implementación con Pipeline



Objetivo y Ventaja

Objetivo: Automatizar el proceso de transformación para que sea reproducible

Ventaja: El proceso es automático, evita la fuga de datos y puede ejecutarse de nuevo fácilmente.

Componentes Clave

- 1.ColumnTransformer: Para aplicar diferentes transformaciones a diferentes tipos de columnas.
- 2.Pipeline para Numéricas: Imputación con SimpleImputer y escalado con StandardScaler.
- 3.Pipeline para Categóricas: Imputación con SimpleImputer y codificación con OneHotEncoder.
- 4.fit_transform(): Se aplica el preprocesador a los datos de entrada (X).

==

Estado final de la calidad de datos

Concepto	Resultado
Registros	De 5100 a 4996 (se eliminaron 104 registros por duplicados e inconsistencias graves).
Variables	De 11 a 14 (aumentaron por la codificación One-Hot de las categóricas).
Valores Faltantes	De 1,335 a 0.
Duplicados	De 100 a 0.
Inconsistencias	De 24 a 0

- Resultado Final: Se generó el archivo rendimiento_academico_limpio.csv, un dataset robusto y listo para la fase de modelado.



Conclusión

Calidad de Datos: El dataset original tenía problemas importantes (nulos, duplicados, valores ilógicos). La corrección de estos fue un paso crítico para obtener conclusiones confiables.

Factores Clave del Rendimiento: El análisis muestra que la disciplina académica (AssignmentsCompleted y Attendance) es un predictor más fuerte que factores como las horas de sueño o el uso de internet.

Importancia de la Preparación: Un proceso de limpieza y transformación bien justificado y reproducible (mediante el uso Pipeline) es fundamental para garantizar la validez de cualquier análisis o modelo predictivo futuro.

